

ACADEMIA DE STUDII ECONOMICE

Facultatea de Cibernetică, Statistică și Informatică

Economică

Proiect Pachete Software

Analiza operațională a companiei aeriene Delta Airlines
prin intermediul pachetelor software

Student:

Ionescu Sabina

Grupa: 1091

Seria: D

Python

1. Definirea problemei – obiectivul economic vizat

În industria aviatică modernă, eficiența operațională este direct legată de profitabilitatea companiei. Pentru organizația analizată, Delta Airlines, fiecare minut de întârziere pe pistă sau în aer generează costuri substanțiale: consum suplimentar de combustibil, penalități către autoritățile aeroportuare, perturbarea programului echipajelor și scăderea satisfacției clienților.

Obiectivul acestui modul informatic realizat în Python (Streamlit) este de a construi un instrument care să permită managementului Delta Airlines să monitorizeze volumul zborurilor, să identifice hub-urile care generează blocaje operaționale și să aplice algoritmi de Machine Learning pentru a segmenta zborurile în profile de risc și a analiza impactul distanțelor asupra decalajelor orare.

2. Descrierea variabilelor utilizate

Analiza se bazează pe extragerea unui set de date operaționale companiei Delta Air Lines, materializat în fișierul `date_delta.csv`. Setul cuprinde un volum masiv de date (peste 430,000 de înregistrări), reflectând zborurile programate. Setul de date a fost preluat de pe Kaggle, Flight Delays Dataset (<https://www.kaggle.com/datasets/umeradnaan/flight-delays-dataset?resource=download>) și prelucrat pentru a păstra doar zborurile Delta Airlines.

- **FlightID** (Numeric, Întreg): Identificatorul unic de sistem al fiecărei înregistrări, utilizat ca cheie primară pentru indexare, sortare și asigurarea integrității structurale a bazei de date.
- **Airline** (Alfanumeric/String): Denumirea companiei aeriene operatoare. În acest set de date, variabila are o valoare constantă (Delta), definind perimetrul analizei la nivelul acestei organizații.
- **FlightNumber** (Numeric, Întreg): Numărul comercial al cursei aeriene alocat de companie pentru identificarea rutei în orarul public.
- **Origin** (Alfanumeric/String): Codul oficial IATA format din 3 litere care indică aeroportul de plecare (ex: LAX, ORD, ATL), reprezentând nodurile de origine ale rețelei.
- **Destination** (Alfanumeric/String): Codul oficial IATA al aeroportului de sosire, definind destinațiile finale ale fluxurilor de pasageri și aeronave.
- **ScheduledDeparture** (Dată/Timp): Timestamp-ul (data și ora) oficiale la care zborul era programat să decoleze conform planificării inițiale.

- ActualDeparture (Dată/Timp): Timestamp-ul real la care aeronava a părăsit pista, utilizat în corelație cu cel planificat pentru a determina abaterile logistice.
- ScheduledArrival (Dată/Timp): Timestamp-ul estimat și planificat pentru aterizarea la destinație.
- ActualArrival (Dată/Timp): Timestamp-ul real la care aeronava a atins pista la aeroportul de sosire.
- DelayMinutes (Numeric, Întreg): Indicatorul de performanță central (variabila dependentă în modelele avansate). Valorile pozitive exprimă minutele de întârziere efectivă acumulată; valorile negative sau nule reprezintă zboruri care au operat la timp sau au fost devansate.
- DelayReason (Alfanumeric/Categorie): Motivul determinant al decalajului orar. Include categorii precum Weather (Condiții meteo nefavorabile), Maintenance (Probleme tehnice/mentenanță) și Air Traffic Control (Restricții de trafic aerian), prezentând valori lipsă în cazul zborurilor punctuale.
- Cancelled (Boolean/Logică: True/False): Variabilă de tip indicator care marchează dacă zborul a fost anulat complet înainte de decolare.
- Diverted (Boolean/Logică: True/False): Variabilă de tip indicator care semnalează dacă aeronava a fost redirecționată către un aeroport de rezervă, diferit de destinația planificată inițial.
- AircraftType (Alfanumeric/String): Modelul structural al aeronavei alocate pentru cursă (ex: Boeing 737, Boeing 777, Airbus A320), esențial pentru analiza eficienței și capacității pe tip de flotă.
- TailNumber (Alfanumeric/String): Numărul de înmatriculare unic al aeronavei (echivalentul numărului de șasiu la mașini), utilizat pentru urmărirea individuală a fiecărui avion în rotația flotei.
- Distance (Numeric, Întreg): Distanța fizică a rutei aeriene exprimate în mile marine, utilizată ca predictor principal în analiza corelațiilor spațio-temporale.

3. Metode de calcul, algoritmi, formule de calcul

Sistemul informatic adoptă o arhitectură modernă, fiind dezvoltat în limbajul Python utilizând următoarele pachete software specializate:

- Streamlit: Utilizat pentru implementarea structurii multi-pagină a aplicației (Cerința 1) prin intermediul fișierului rădăcină main.py și a folderului nativ

4.2. Pagina de Management și Filtrare (1_Statistici_si_Filtrare.py)

- Filtrare Interactivă (Cerința 2): Implementează un widget de selecție (st.selectbox) bazat pe lista unică a aeroporturilor de origine, recalculând instantaneu toate tabelele din pagină.

1. Filtrare Interactivă după Aeroport

Selectați Aeroportul de Origine (Origin):

ATL

- Curățarea Datelor (Cerința 4): Identifică valorile de tip NaN (Missing) din coloana DelayReason. Din punct de vedere economic, un spațiu lipsă indică un zbor care a decurs normal sau al cărui motiv nu a fost înregistrat. Sistemul rulează .fillna('Fără întârziere'), eliminând erorile de calcul statistic.

2. Curățarea Datelor (Tratarea Valorilor Lipsă)

Valori lipsă în coloana DelayReason înainte de tratare: 23651

Tratare finalizată! Valori lipsă rămase în DelayReason: 0 (Înlocuite cu succes cu textul 'Fără întârziere')

- Metrice Specifice (Cerința 11): Afișează în containere vizuale de tip card valorile agregate pentru: Total zboruri operate din hub, Media minutelor de întârziere și Total zboruri anulate.

3. Metricile Specifice ale Hub-ului de Plecare

Total Zboruri Operate

87,622

Întârziere Medie Globală

9.95 min

Zboruri Anulate

43625

- Agregare și Accesare (Cerințele 6 și 7): Rulează gruparea zborurilor după destinație, calculând numărul de curse și întârzierile medii. În paralel, exemplifică extragerea zborurilor deviate cu .loc și selectarea primelor 3 rânduri operative cu .iloc.

Agregare Date pe Destinații (groupby)

Top 5 destinații și indicatorii lor de timp agregați:

Destination	Numar_Zboruri	Medie_Intarziere_Min	Distanța_Medie_Mile
SEA	17579	10.103	1546.1254
BOS	17577	9.8467	1548.3616
MIA	17561	9.9945	1549.5273
SFO	17507	10.0364	1552.5849
JFK	17398	9.7677	1543.7928

Tehnici de Accesare Structurală (loc & iloc)

Filtrare cu .loc (Zboruri deviate / Diverted = True):

FlightNumber	Destination	AircraftType
19	5746 BOS	Airbus A320
39	3548 SEA	Boeing 777
44	5484 SFO	Boeing 737

Extragere pozițională cu .iloc (Primele 3 rânduri și 4 coloane structurale):

FlightID	Airline	FlightNumber	Origin
8	27 Delta	6219	ATL
17	54 Delta	5850	ATL
19	58 Delta	5746	ATL

4.3 Modulul Analitic Avansat (2_Grafice_si_Codificare.py)

- Codificare (Cerința 5): Mapează etichetele text în ID-uri numerice pentru a permite procesarea matematică.


1. Pregătirea Datelor prin Codificare (Label Encoding)

Transformăm caracteristica text `AircraftType` într-o variabilă numerică unică:

	AircraftType	AircraftType_Codificat	Destination	Destination_Codificat
0	Airbus A320		0 MIA	2
1	Boeing 777		2 BOS	0
2	Boeing 737		1 SEA	3
3	Boeing 777		2 SFO	4
6	Boeing 737		1 JFK	1

- Grafic Interactiv (Cerința 8): Un scatter plot dinamic corelează distanța rutelor cu minutele de întârziere, fiind controlat în timp real de un widget de tip `st.slider` (Cerința 2) pentru distanță.

2. Analiză Vizuală Dinamică (Plotly Scatter Chart)



- Clusterizare K-Means (Cerința 9): Segmentează eșantionul operațional în 3 clustere bazate pe vectorul spațial format din distanță și timp de întârziere. Rezultatul este ilustrat printr-un grafic interactiv de tip plăcintă (Pie Chart) realizat în Plotly, arătând ponderea fiecărui profil de zbor determinat.

3. Segmentarea Zborurilor cu Scikit-Learn (K-Means)

Grupăm zborurile în 3 segmente operaționale distincte în funcție de `distance` și `DelayMinutes`:

💡 Ghid de Interpretare Economică a Clusterelor

Algoritmul **K-Means** a segmentat automat cele 5,000 de zboruri Delta în 3 grupuri distincte, utilizând ca axe matematice două criterii operaționale esențiale:

- **Distanța zborului (Distance):** Pentru a separa rutele scurt-curier (regionale) de cele lung-curier (transcontinentale).
- **Amplitudinea întârzierii (DelayMinutes):** Pentru a izola zborurile punctuale de cele care generează pierderi financiare severe.

Cum interpretăm cele 3 profile determinate în tabelul de mai sus:

1. **Zboruri Regionale Standard:** Clusterul caracterizat prin distanță medie mică și minute de întârziere minime. Reprezintă nucleul stabil și predictibil al operațiunilor zilnice Delta.
2. **Zboruri Transcontinentale Eficiente:** Clusterul cu distanță medie mare, dar cu un nivel scăzut de întârzieri. Demonstrează că rutele lungi sunt bine optimizate și nu acumulează decalaje orare din cauza distanței.
3. **Zboruri Critice (Zona de Risc):** Clusterul care înregistrează cele mai mari valori în coloana `DelayMinutes`, indiferent de lungimea rutei. Aceasta este grupa problematică pe care managementul Delta Air Lines trebuie să o monitorizeze, penalitățile și costurile cu compensațiile pasagerilor fiind concentrate aici.

Caracteristicile medii ale clusterelor identificate:

Cluster	Distance	DelayMinutes
0	0	1526.5348
1	1	2509.5169
2	2	565.7599

- Regresie Multiplă OLS (Cerința 10 și 11): Rulează ecuația econometrică estimând variabila `DelayMinutes` în funcție de predictorii `Distance` și `Destination_Codificat`, afișând coeficientul de determinare R^2 ca metrică de performanță. (Aici se inserează Captura de ecran 3: Graficele Plotly și output-ul modelelor predictive)

4. Model de Regresie Multiplă cu Statsmodels

Analizăm impactul predictorilor `Distance` și `Destination_Codificat` asupra variabilei țintă `DelayMinutes`:

Metrii Specifice rezultate din Regresie:

R-squared (Coeficientul de determinare)

0.0001

F-statistic (Valoarea p a modelului)

0.8775

>  [Vezi raportul matematic complet \(Sumar OLS\)](#)

5. Interpretare economica:

Rularea aplicației pe setul de date de la Delta Air Lines a furnizat rezultate, evidențiind aspecte analitice fundamentale:

Profilarea Clusterelor (K-Means): Algoritmul a separat cu precizie fluxurile de trafic în trei tipare operaționale: Zboruri Regionale Standard: Volum ridicat, distanțe mici, punctualitate excelentă. Reprezintă nucleul stabil al afacerii. Zboruri

Transcontinentale Eficiente: Distanțe mari, dar timpi de întârziere extrem de reduși.

Acest lucru demonstrează eficiența planificării pe rute lung-curier. Zboruri Critice

(Zona de Risc): Un grup compact de zboruri care acumulează întârzieri masive,

indiferent de distanța lor. Această concluzie indică faptul că riscul operațional nu este determinat fizic de lungimea zborului, ci de disfuncționalități la sol sau de nodurile de

rețea afectate de factori externi. **Infirmarea Ipotezei prin Regresie (OLS):** Analiza econometrică a înregistrat un coeficient R^2 extrem de mic (aproape de 0), iar testul statistic indică lipsa unei relații liniare între distanța parcursă și minutele de întârziere la sosire.

Recomandare Strategică pentru Managementul Delta Air Lines: Deoarece modelul dovedește științific că lungimea rutei nu influențează liniar timpii de întârziere, managementul executiv nu trebuie să penalizeze sau să restructureze rutele lung-curier. Resursele financiare și logistice trebuie direcționate către gestionarea factorilor evidențiați de curățarea datelor din coloana `DelayReason`: implementarea algoritmilor de mentenanță predictivă a aeronavelor (reducerea Maintenance), optimizarea resurselor în hub-urile afectate frecvent de fenomene meteo (Weather) și renegocierea sloturilor cu autoritățile de control al traficului aerian (Air Traffic Control). Distanța în sine nu generează întârzieri; logistica punctelor de tranzit este cea care determină succesul operațional.

SAS

1. Definirea problemei:

În timp ce modulul dezvoltat în Python s-a concentrat pe interfața grafică și modelele predictive, pilonul de procesare grea a datelor din cadrul companiei Delta Air Lines este implementat în mediul SAS (Statistical Analysis System). SAS reprezintă standardul global în industria aviatică pentru securitatea datelor, procesarea fluxurilor masive de tranzacții și raportarea statistică de înaltă precizie.

2. Metode de calcul, algoritmi, formule

- Procedura PROC IMPORT: Responsabilă pentru maparea fișierului extern date_delta.csv într-un set de date proprietar SAS (delta_raw). Procedura analizează automat separatorii și extrage metadatele.
- Procedura PROC FORMAT și Pasul DATA de aplicare: Definirea de dicționare utilizator (\$delay., cancelfmt., divertfmt.) pentru a mapa variabilele brute (0/1 sau coduri text) în string-uri descriptive, optimizând spațiul de stocare.
- Logică Condițională (IF-THEN/ELSE) și Iterativă (DO LOOP): Utilizate în pasul de date delta_proc pentru a construi un indicator sintetic de risc operațional (ProblemFlight) și pentru a rula o buclă incrementală bazată pe volumul minutelor de întârziere.
- Funcții SAS de Dată și Timp (INTCK, DATEPART, MONTH): Funcții speciale destinate procesării structurilor de tip Timestamp. intck calculează intervalul de minute dintre două momente, datepart izolează componenta calendaristică dintr-o dată completă, iar month extrage luna aferentă operării.
- Procedura PROC UNIVARIATE: O procedură statistică avansată utilizată pentru analiza exhaustivă a unei variabile numerice, calculând momentele inferențiale, asimetria, boltirea și generând grafice de distribuție.
- Procedura PROC MEANS: Utilizată pentru raportarea statistică agregată pe clase (grupare multidimensională în funcție de destinație).

3. Rezultate

Prin intermediul PROC IMPORT, setul de date este încărcat în librăria de lucru. Rularea ulterioară a procedurii PROC CONTENTS validează structura internă, confirmând încărcarea coloanelor și a tipurilor de date asociate. Comanda proc print data=delta_raw (obs=10); permite listarea primelor 10 observații pentru un audit vizual rapid al consistenței datelor.


Obs	FlightID	Airline	FlightNumber	Origin	Destination	ScheduledDeparture	ActualDeparture	ScheduledArrival	ActualArrival	DelayMinutes	DelayReason	Cancelled	
1	2	Delta	8021	LAX	MIA	01SEP24:10:25:00	01SEP24:10:41:00	01SEP24:13:25:00	01SEP24:13:27:00	2	Air Traffic Control	True	·
2	4	Delta	2046	ORD	BOS	01SEP24:14:44:00	01SEP24:15:04:00	01SEP24:18:44:00	01SEP24:18:34:00	-10		False	!
3	5	Delta	6049	LAX	SEA	01SEP24:01:51:00	01SEP24:02:08:00	01SEP24:05:51:00	01SEP24:06:15:00	24	Air Traffic Control	False	·
4	15	Delta	2478	ORD	SFO	01SEP24:13:54:00	01SEP24:14:05:00	01SEP24:18:54:00	01SEP24:19:20:00	26	Weather	False	·
5	20	Delta	6494	LAX	SEA	01SEP24:23:17:00	01SEP24:23:37:00	02SEP24:04:17:00	02SEP24:04:33:00	16	Air Traffic Control	True	·
6	23	Delta	9464	LAX	MIA	01SEP24:23:26:00	01SEP24:23:55:00	02SEP24:01:26:00	02SEP24:01:51:00	25	Maintenance	False	!
7	24	Delta	8277	JFK	JFK	01SEP24:01:27:00	01SEP24:01:40:00	01SEP24:02:27:00	01SEP24:02:53:00	26	Maintenance	True	!
8	26	Delta	5396	JFK	SFO	01SEP24:08:33:00	01SEP24:09:01:00	01SEP24:09:33:00	01SEP24:09:59:00	26	Air Traffic Control	True	·
9	27	Delta	6219	ATL	SEA	01SEP24:12:08:00	01SEP24:12:09:00	01SEP24:18:08:00	01SEP24:18:31:00	23	Maintenance	True	!
10	28	Delta	6347	LAX	JFK	01SEP24:22:55:00	01SEP24:23:15:00	02SEP24:03:55:00	02SEP24:03:59:00	4	Maintenance	True	·

Pasul data delta_fmt; preia datele brute și le atașează formatele stocate în catalog. Astfel, valorile logice din coloanele Cancelled și Diverted (stocate intern ca booleene

sau 0/1) sunt afișate sub formă de text explicit ("Da" / "Nu"), crescând lizibilitatea rapoartelor fără a mări dimensiunea fișierului fizic.

În cadrul pasului delta_proc, se definește variabila ProblemFlight. Dacă un zbor a înregistrat o întârziere mai mare de 0 minute, A FOST ANULAT (Cancelled=1) sau A FOST DEVIAT (Diverted=1), acesta primește flag-ul de alarmă 1.

Distribuția Întârzierilor (PROC UNIVARIATE): Analizează variabila DelayMinutes, generând tabele de cuantile și momente, evidențiind comportamentul asimetric al întârzierilor (majoritatea zborurilor sunt concentrate în jurul valorii 0, distribuția având o coadă lungă spre dreapta din cauza cazurilor extreme). Statistici pe Destinații (PROC MEANS): Grupează setul de date după variabila Destination. Pentru fiecare aeroport de sosire în parte, SAS calculează volumul (\$N\$), media, deviația standard, minimul și maximum pentru minutele de întârziere și durata reală a zborului.



Statistici pe destinații

The MEANS Procedure

Destination	N Obs	Variable	N	Mean	Std Dev	Minimum	Maximum
BOS	87300	DelayMinutes	87300	9.9853379	11.8244253	-10.0000000	30.0000000
		ActualDuration	87300	205.4275716	103.5040103	20.0000000	390.0000000
JFK	87266	DelayMinutes	87266	9.9799120	11.8143558	-10.0000000	30.0000000
		ActualDuration	87266	204.7207733	103.9850402	20.0000000	390.0000000
MIA	87341	DelayMinutes	87341	10.0092854	11.8127777	-10.0000000	30.0000000
		ActualDuration	87341	205.3130145	103.4594928	20.0000000	390.0000000
SEA	87545	DelayMinutes	87545	10.0431093	11.8112823	-10.0000000	30.0000000
		ActualDuration	87545	204.8502599	103.4023579	20.0000000	390.0000000
SFO	87228	DelayMinutes	87228	9.9747214	11.8147777	-10.0000000	30.0000000
		ActualDuration	87228	205.7979662	103.4482841	20.0000000	390.0000000

4. Interpretarea rezultatelor

Analiza statistică rulată în SAS oferă o perspectivă clară asupra performanței operaționale a companiei Delta Air Lines:

Analiza Duratelor prin INTCK: Din calculul diferenței de durată (DurationDiff), managementul poate observa direct dacă aeronavele recuperează timp în aer sau dacă, din contră, timpii de zbor reali depășesc semnificativ planificarea inițială. O valoare medie ridicată a DurationDiff pe anumite rute indică o subdimensionare a timpilor în orarul oficial, necesitând o corecție de planificare.

Segmentarea pe Destinații (PROC MEANS): Gruparea indicatorilor pe aeroporturile de sosire scoate la iveală eficiența specifică a rutelor. Destinațiile care înregistrează o deviație standard uriașă a variabilei DelayMinutes indică o instabilitate majoră a aceluia aeroport (probleme cronice de trafic sau infrastructură locală). Managementul Delta trebuie să folosească aceste date pentru a renegocia contractele de deservire la sol (ground handling) sau pentru a modifica sloturile orare alocate acelor destinații.

Indicatorul Sintetic de Problemă (ProblemFlight): Centralizarea zborurilor anulate, deviate sau întârziate într-o singură variabilă booleană permite departamentului de audit să extragă instantaneu rata de eșec operațional a companiei. Reducerea procentajului de zboruri cu ProblemFlight = 1 reprezintă KPI-ul principal pentru evaluarea performanței managerilor de Hub.

Concluzii:

Privind rezultatele pe curat, iată concluziile concrete de business:

- Distanța nu este o scuză pentru întârzieri: Atât graficele, cât și modelele matematice (regresia) au demonstrat clar că nu există o legătură între lungimea unei rute și minutele de întârziere. Zborurile lungi sunt la fel de bine organizate ca cele scurte. Deci, managerii Delta nu trebuie să modifice rutele lungi, pentru că nu de acolo apar problemele.
- Problema e la sol, nu în aer: Algoritmul de clusterizare a izolat un grup de zboruri cu întârzieri uriașe, dar care aveau distanțe complet diferite. Asta ne spune că riscul operațional nu ține de avion sau de rută, ci de ce se întâmplă în aeroporturile de tranzit (hub-uri).
- Unde trebuie trimiși banii: Din moment ce am văzut că motivele principale de blocaj sunt legate de meteo, mentenanță și controlul traficului aerian (ATC), recomandările logice pentru management sunt:
- Să investească în mentenanță predictivă pentru avioane (să repare piesele înainte să se strice și să blocheze pista).
- Să renegocieze sloturile orare pe aeroporturile aglomerate, ca să nu mai stea avioanele la coadă (ATC).

- Să optimizeze turele echipajelor ca să nu propage întârzierea de la un zbor la altul.

Pe scurt, aplicația demonstrează că dacă vrei o companie aeriană punctuală, trebuie să rezolvi logistica din aeroporturi, deoarece distanța zborului în sine nu este un factor de risc.